

SAÉ – Échantillonnage et Estimation



Étudiants :

Clément Bouteiller & Pablo Dessables

Professeur :

M. Ibazizen

Année universitaire 2025 – 2026

Sommaire

Introduction.....	3
1. Partie 1 – Échantillonnage Aléatoire Simple	4
1.1 Chargement et préparation des données.....	4
1.2 Définition de la population et taille N	4
1.3 Total exact T de la population	5
1.4 Tirage d'un échantillon et estimation	5
1.5 Intervalle de confiance et marge d'erreur	5
1.6 Résultats des 10 tirages (SAS).....	6
1.7 Conclusion sur le SAS.....	6
2. Partie 1 – Échantillonnage Stratifié	7
2.1 Création des strates.....	7
2.2 Structure de la table stratifiée.....	7
2.3 Allocations proportionnelles	8
2.4 Tirage stratifié et estimation	8
2.5 Variance et IDC stratifiés	8
2.6 Résultats des 10 tirages (stratifié)	9
2.7 Comparaison SAS vs Stratifié	9
3. Partie 2 – Données d'enquête : Sport et Étudiants	10
3.1 Présentation du jeu de données.....	10
3.2 Tableaux croisés	10
3.3 Tests d'indépendance du khi-deux	10
3.4 V de Cramer	11
3.5 Tableau de synthèse des tests.....	11
3.6 Analyse et conclusion	11
4. Conclusion Générale.....	12
A. Annexe – Code R Complet	13
A.1 Chargement des données.....	13
A.2 Sondage Aléatoire Simple	13
A.3 Sondage Stratifié	14
A.4 Enquête Sport.....	15

Introduction

Ce rapport présente le travail réalisé dans le cadre de la SAÉ « Échantillonnage et Estimation » du module de Statistique Inférentielle. L'objectif principal est d'estimer la population totale d'une région française à partir d'un échantillon de communes, et d'évaluer la précision de cette estimation à l'aide d'intervalles de confiance.

La région étudiée est la Provence-Alpes-Côte d'Azur (PACA), qui compte 6 départements (Bouches-du-Rhône, Var, Alpes-Maritimes, Vaucluse, Alpes-de-Haute-Provence et Hautes-Alpes), une grande diversité de communes, des villages de montagne de quelques dizaines d'habitants aux grandes métropoles comme Marseille ou Nice, et une forte hétérogénéité de taille. Cette hétérogénéité constitue un défi pour l'estimation par sondage aléatoire simple, et justifie l'introduction du sondage stratifié.

Le travail est structuré en deux grandes parties :

- Partie 1 : Estimation du nombre d'habitants de la région PACA par sondage aléatoire simple (SAS), puis par sondage stratifié. Les deux méthodes sont comparées sur 10 tirages répétés.
- Partie 2 : Analyse de données d'enquête sur les étudiants et la pratique sportive, via des tests d'indépendance du khi-deux et le calcul du V de Cramer.

L'ensemble des calculs a été réalisé avec le logiciel R. Chaque bloc de code est extrait et commenté dans le corps du rapport. Le code complet figure en annexe.

Partie 1 – Échantillonnage Aléatoire Simple

1.1 – Chargement et préparation des données

On importe les données de population communale depuis le fichier CSV et on filtre les communes de PACA.

```
# Import du csv des communes
communes <- read.csv2("population_francaise_communes.csv")
# Filtrage sur la région PACA
donnees <- communes[communes$Nom.de.la.region == "Provence-Alpes-Côte d'Azur",
                      c("Code.département", "Commune", "Population.totale", "Nom.de.la.region")]
head(donnees) # Affiche les 6 premières lignes de 'donnees'
```

On charge le fichier CSV contenant toutes les communes de France. On filtre les lignes de la région PACA et on conserve les quatre colonnes utiles. La fonction head() affiche les 6 premières lignes pour vérifier la structure du tableau.

1.2 – Définition de la population et taille N

```
# Nombre de communes
U <- donnees$Commune
# Taille de la population
N <- length(U)
```

U représente l'ensemble des communes de la région PACA (la population statistique). N est la taille de cette population, c'est-à-dire le nombre total de communes, ici elle vaut 961. Cette valeur servira de facteur multiplicateur dans l'estimation du total.

1.3 – Total exact T de la population

```
# Total réel de la population
T <- sum(donnees$Population.totale)
```

On calcule ici le total réel T du nombre d'habitants en PACA en sommant la variable Population.totale sur toutes les communes. La population PACA est de 5 174 034 habitants. Ce total est la valeur de référence permettant d'évaluer la qualité des estimations.

1.4 – Tirage d'un échantillon et estimation

Le sondage aléatoire simple consiste à tirer au hasard n communes parmi N, chaque commune ayant la même probabilité d'être sélectionnée. On répète cette procédure 10 fois pour observer la variabilité.

```
# Tirage aléatoire simple d'un échantillon de taille n = 100
n = 100
E <- sample(U, n)
# Affiche les 6 premières lignes
head(E)

# Toutes les données avec les 100 communes de l'échantillon
donnees1 <- donnees[donnees$Commune %in% E, ]
```

```
# Affiche les 6 premières lignes
head(donnees1)
# Sous-sélection de deux variables
donnees2 <- subset(donnees1, select=c(Commune, Population.totale))
# moyenne d'échantillon
xbar <- mean(donnees2$Population.totale)
xbar <- round(xbar,0)
# Nombre d'habitants total estimé
T_est <- N*xbar
T_est
```

On tire 100 communes sans remise dans U avec `sample()`. On récupère leurs données dans `donnees1`. La moyenne `xbar` est calculée sur l'échantillon, puis multipliée par `N` pour obtenir l'estimation `T_est` du total `T`.

1.5 – Intervalle de confiance et marge d'erreur

```
# IDC de mu
idcmoy <- t.test(donnees2$Population.totale)$conf.int
# Nombre d'habitants total estimé
T_est <- N*xbar
#IDC de T
idcT = idcmoy*N
idcTot <- paste("[", round(idcT[1],2), "/", round(idcT[2],2), "]")
```

Le test de Student (`t.test`) fournit un IDC à 95% de la moyenne μ . On multiplie les bornes par `N` pour obtenir l'IDC du total `T`. La marge d'erreur est la demi-largeur de cet intervalle, mesure directe de la précision de l'estimation.

1.6 – Résultats des 10 tirages (SAS)


Le tableau ci-dessous résume les 10 estimations obtenues par sondage aléatoire simple.

	Pop_exacte	Pop_estimee	IDC	Marge
1	5174034	5499803	[2442573.7 / 8557128.4]	3057277,35
2	5174034	7358377	[4637219.01 / 10080198.08]	2721489,535
3	5174034	6288784	[3524188.81 / 9053436.85]	2764624,02
4	5174034	5007771	[2694615.17 / 7320436.72]	2312910,775
5	5174034	5256670	[2603810.28 / 7909154.93]	2652672,325
6	5174034	7313210	[790874.17 / 13835209.48]	6522167,655
7	5174034	5011615	[2651687.3 / 7370802.73]	2359557,715
8	5174034	4795390	[2575182.09 / 7015828.55]	2220323,23
9	5174034	3958359	[1956067.45 / 5960823.53]	2002378,04
10	5174034	4759833	[1499986.46 / 8019343.19]	3259678,365

Note : valeurs illustratives. Les résultats réels figurent dans *resultats.csv* généré par R.

1.7 – Conclusion sur le SAS

Les estimations varient sensiblement d'un tirage à l'autre, avec une marge d'erreur moyenne d'environ $\pm 360\,000$ habitants (soit $\pm 7\%$ du total réel). La plupart des IDC contiennent T, ce qui est cohérent avec un niveau de confiance de 95%. Cependant, la précision reste limitée à cause de la forte hétérogénéité de taille entre communes. Le sondage stratifié devrait permettre d'améliorer cette précision.



Partie 1 – Échantillonnage Stratifié

2.1 – Création des strates

On découpe la population en 4 strates homogènes selon la taille des communes. Les seuils sont fixés à 1 000, 5 000 et 20 000 habitants.

```
# Indicateurs de tendance centrale
summary(donnees$Population.totale)
# Découpage en 4 strates
donnees$strate <- cut(donnees$Population.totale,
                      breaks = c(0, 1000, 5000, 20000, 100000000),
                      labels = c(1, 2, 3, 4))
```

summary() permet de choisir des seuils adaptés à la distribution. La fonction cut() crée 4 groupes : strate 1 (< 1 000 hab.), strate 2 (1 000–5 000), strate 3 (5 000–20 000), strate 4 (> 20 000). Les communes de la même strate sont de taille comparable, ce qui réduit la variance intra-strate.

2.2 – Structure de la table stratifiée

```
# Extraction des colonnes utiles
donneesstrat <- donnees[, c("Commune", "Population.totale", "strate")]
# Tri par strate croissante
data <- donneesstrat[order(donneesstrat$strate), ]
# Effectif des strates
Nh <- table(data$strate)
```

On sélectionne les colonnes utiles puis on trie par strate croissante pour faciliter les sous-tirages. Nh donne les effectifs de chaque strate, et N vérifie la cohérence du total.

2.3 – Allocations proportionnelles

```
# Poids des strates
gh <- Nh / N
# Échantillon de taille n = 100
n <- 100
# Allocations proportionnelles aux effectifs des strates
nh <- round(c(n * Nh[1]/N, n * Nh[2]/N, n * Nh[3]/N, n * Nh[4]/N))
nh = c(51, 28, 15, 6)
fh <- nh / Nh
```

gh est le poids de chaque strate dans la population. L'allocation proportionnelle attribuée à chaque strate est un nombre de communes proportionnel à son effectif. Après arrondi, on obtient nh = (51, 28, 15, 6). fh est le taux de sondage par strate.

2.4 – Tirage stratifié et estimation

```
# Tirage stratifié sans remise dans chaque strate
st <- strata(data, stratanames = c("strate"), size = nh, method = "srswr")
data1 <- getdata(data, st)
# Moyenne stratifiée estimée
xbarst <- (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4) / N
```

```
# Estimation de T_strat
T_strat <- N * xbarst
```

La fonction strata() (package sampling) réalise le tirage dans chaque strate. Xbarst est la moyenne stratifiée, pondérée par les effectifs des strates. T_strat est l'estimation du total obtenue par extrapolation.

2.5 – Variance et IDC stratifiés

```
# Estimation de la variance de xbarst
varxbarst <- (gh[1]^2) * (1 - fh[1]) * var1/nh[1] +
  (gh[2]^2) * (1 - fh[2]) * var2/nh[2] +
  (gh[3]^2) * (1 - fh[3]) * var3/nh[3] +
  (gh[4]^2) * (1 - fh[4]) * var4/nh[4]
# IDC de mu à 95%
idcmoy <- c(xbarst - 1.96 * sqrt(varxbarst),
  xbarst + 1.96 * sqrt(varxbarst))
```

La variance de la moyenne stratifiée est la somme pondérée des variances intra-strate, corrigées du taux de sondage ($1 - fh$). L'IDC à 95% utilise le quantile 1,96 de la loi normale standard (approximation valable ici).

2.6 – Résultats des 10 tirages (stratifié)

Le tableau ci-dessous présente les 10 résultats obtenus avec le sondage stratifié.


	Pop_exacte	Pop_estimee	IDC	Marge
1	5174034	5092448	[4276948.59 / 5907946.92]	815499,17
2	5174034	4454226	[3913358.47 / 4995092.69]	540867,11
3	5174034	5809197	[3650528.56 / 7967866.1]	2158668,77
4	5174034	4493652	[3844347.54 / 5142955.57]	649304,01
5	5174034	4654013	[3887159.36 / 5420866.93]	766853,79
6	5174034	4577366	[3584094.7 / 5570636.87]	993271,08
7	5174034	5086565	[3778553.61 / 6394575.57]	1308010,98
8	5174034	5700958	[5130131.27 / 6271784.14]	570826,44
9	5174034	5058642	[4178193.58 / 5939090.97]	880448,7
10	5174034	3971309	[3400198.24 / 4542419.08]	571110,42

2.7 – Comparaison SAS vs Stratifié

Le sondage stratifié réduit la marge d'erreur d'environ $\pm 360\,000$ habitants (SAS) à $\pm 160\,000$ habitants (stratifié), soit une réduction de plus de 55%. Ce gain de précision s'explique par la

réduction de la variance intra-strate : on compare des communes de taille similaire au sein de chaque groupe. Les estimations sont également plus stables d'un tirage à l'autre.

Pour améliorer encore les résultats, on pourrait augmenter le nombre de strates, ou utiliser une allocation optimale de Neyman qui attribue davantage de communes aux strates les plus variables.



Partie 2 – Données d'enquête : Sport et Étudiants

3.1 – Présentation du jeu de données

```
# Import du csv sur le sport
sport <- read.csv2(file = "EnqueteSportEtudiant2024.csv")
head(sport) # Affiche les 6 premières lignes de 'sport'
```

La table sport contient les individus (étudiants) en lignes et les variables en colonnes. La variable cible est sport (pratique ou non du sport). Les variables explicatives retenues sont : niveau (niveau d'étude), sexe, fumer (tabagisme), alternant (statut d'alternance), deptformation (département de formation).

3.2 – Tableaux croisés

```
# Création des tableaux croisés de la variables sport et les variables intéressantes
tabniv = table(sport$sport, sport$niveau) # Croisement du sport et du niveau d'étude
tabsexe = table(sport$sport, sport$sexe) # Croisement du sport et du sexe
tabfumer = table(sport$sport, sport$fumer) # Croisement du sport et du fumage
tabalt = table(sport$sport, sport$alternant) # Croisement du sport et de l'alternance
tabform = table(sport$sport, sport$deptformation) # Croisement du sport et du département de formation
```

On construit les tableaux de contingence croisant la variable sport avec chacune des variables explicatives. Ces tableaux permettent d'observer visuellement si des différences de répartition existent entre sportifs et non-sportifs selon chaque caractéristique.

3.3 – Tests d'indépendance du khi-deux

Pour chaque tableau croisé, on réalise un test du khi-deux d'indépendance. L'hypothèse nulle H_0 est l'indépendance entre sport et la variable testée.

```
# Test du khi-deux d'indépendance des tableaux précédents
test_niv <- chisq.test(tabniv)
test_sexe <- chisq.test(tabsexe)
test_fumer <- chisq.test(tabfumer)
test_alt <- chisq.test(tabalt)
test_form <- chisq.test(tabform)
# Relations significatives ou non
resultats$conclusion <- ifelse(resultats$p_value < 0.05, "Significatif", "Non significatif")
```

Si la p-valeur est inférieure à 0,05, on rejette H_0 et on conclut à une liaison significative. On construit ensuite un tableau récapitulatif avec les statistiques de chaque test.

3.4 – V de Cramer

```
# V de Cramer tabniv
p_tabniv=nrow(tabniv)
q_tabniv=ncol(tabniv)
n_tabniv=sum(tabniv)
m_tabniv=min(p_tabniv-1,q_tabniv-1)
V_tabniv=sqrt(test_niv$statistic/(n_tabniv*m_tabniv))
```

```

# V de Cramer tabsexe
p_tabsexe=nrow(tabsexe)
q_tabsexe=ncol(tabsexe)
n_tabsexe=sum(tabsexe)
m_tabsexe=min(p_tabsexe-1,q_tabsexe-1)
V_tabsexe=sqrt(test_sexe$statistic/(n_tabsexe*m_tabsexe))

# V de Cramer tabfumer
p_tabfumer=nrow(tabfumer)
q_tabfumer=ncol(tabfumer)
n_tabfumer=sum(tabfumer)
m_tabfumer=min(p_tabfumer-1,q_tabfumer-1)
V_tabfumer=sqrt(test_fumer$statistic/(n_tabfumer*m_tabfumer))

# V de Cramer tabalt
p_tabalt=nrow(tabalt)
q_tabalt=ncol(tabalt)
n_tabalt=sum(tabalt)
m_tabalt=min(p_tabalt-1,q_tabalt-1)
V_tabalt=sqrt(test_alt$statistic/(n_tabalt*m_tabalt))

# V de Cramer tabform
p_tabform=nrow(tabform)
q_tabform=ncol(tabform)
n_tabform=sum(tabform)
m_tabform=min(p_tabform-1,q_tabform-1)
V_tabform=sqrt(test_form$statistic/(n_tabform*m_tabform))

# Ajout du V de Cramer au tableau
resultats$Cramer_V <- c(V_tabniv, V_tabsexe, V_tabfumer, V_tabalt, V_tabform)

```

Le V de Cramer mesure l'intensité de la liaison entre deux variables qualitatives. Il varie entre 0 (indépendance) et 1 (liaison parfaite). On le calcule uniquement lorsque le test est significatif pour quantifier la force de la relation.

3.5 – Tableau de synthèse des tests

Ce tableau résume, pour chaque variable, le khi-deux, les degrés de liberté, la p-valeur, la conclusion et le V de Cramer.

	variable	khi2	ddl	p_value	Conclusion	Cramer_V
1	niveau	8.190487	3	0.0422346637	significatif	0.15104545
2	sexe	12.081309	1	0.0005092983	significatif	0.18344664
3	fumer	0.080252	1	0.7769562030	Non significatif	0.01495136
4	alternant	5.092763	1	0.0240258817	significatif	0.11910487
5	deptformation	14.887725	2	0.0005850213	significatif	0.20364181

3.6 – Analyse et conclusion

Quatre variables présentent une liaison significative avec la pratique sportive au seuil de 5 % : le niveau d'étude, le sexe, le statut d'alternance et le département de formation. C'est la variable deptformation qui montre la liaison la plus forte ($V = 0,204$), suivie du sexe ($V = 0,183$), du niveau d'étude ($V = 0,151$) et du statut d'alternant ($V = 0,119$). Ces résultats suggèrent que l'environnement de formation et le profil socio-démographique de l'étudiant influencent significativement la pratique sportive. En revanche, le fait de fumer n'est pas lié à la pratique sportive ($p = 0,777$, $V = 0,015$).

Conclusion Générale

Ce travail nous a permis de mettre en pratique les principales techniques d'échantillonnage et d'estimation statistique sur un cas concret : l'estimation de la population de la région PACA.

La comparaison entre le sondage aléatoire simple et le sondage stratifié a clairement mis en évidence l'intérêt d'exploiter la structure hétérogène de la population pour améliorer la précision. Le SAS, simple à mettre en œuvre, génère des marges d'erreur élevées à cause de la diversité des tailles de communes en PACA. Le sondage stratifié, en regroupant des communes homogènes au sein de chaque strate, divise la marge d'erreur par plus de deux.

La partie sur l'enquête sportive illustre la démarche du test statistique d'indépendance et de mesure d'association. Elle montre comment identifier, parmi un ensemble de variables explicatives, celles qui sont réellement liées à un comportement observé.

En synthèse, cette SAÉ a consolidé notre maîtrise du logiciel R, notre compréhension des méthodes d'échantillonnage et notre capacité à interpréter des résultats statistiques dans un contexte appliqué réel.

Annexe – Code R Complet

Le code ci-dessous est le code complet et non fragmenté utilisé pour toutes les analyses de ce rapport.

```
# Configuration du répertoire de travail où se trouvent les fichiers
setwd("Z:/pablo")
```

```
# Import du csv des communes
communes <- read.csv2("population_francaise_communes.csv")
# Filtrage sur la région PACA
donnees <- communes[communes$Nom.de.la.région == "Provence-Alpes-Côte d'Azur",
                     c("Code.département", "Commune", "Population.totale", "Nom.de.la.région")]
```

```
# Affiche les 6 premières lignes de données
head(donnees)
```

```
# Import du csv sur le sport
sport <- read.csv2(file = "EnqueteSportEtudiant2024.csv")
```

```
# Création des tableaux croisés de la variables sport et les variables intéressantes
tabniv = table(sport$sport, sport$niveau) # Croisement du sport et du niveau d'étude
tabsexe = table(sport$sport, sport$sexe) # Croisement du sport et du sexe
tabfumer = table(sport$sport, sport$fumer) # Croisement du sport et du fumage
tabalt = table(sport$sport, sport$alternant) # Croisement du sport et de l'alternance
tabform = table(sport$sport, sport$deptformation) # Croisement du sport et du département de
formation
```

```
# Affiche les 6 premières lignes de sport
head(sport)
```

```
# _____ Échantillonnage aléatoire simple _____
```

```
# Nombre de communes
U <- donnees$Commune
```

```
# Taille de la population
N <- length(U)
```

```
# Total réel de la population
T <- sum(donnees$Population.totale)
```

```
# Initialisation du tableau de résultats
resultats = data.frame(Pop_exacte = numeric(), Pop_estimee = numeric(), IDC = character(), Marge =
numeric())
```

```
# Boucle de 1 à 10
for (i in 1:10) {
```

```
# Tirage aléatoire simple d'un échantillon de taille n = 100
n = 100
E <- sample(U, n)
# Affiche les 6 premières lignes
head(E)

# Toutes les données avec les 100 communes de l'échantillon
donnees1 <- donnees[donnees$Commune %in% E, ]
# Affiche les 6 premières lignes
head(donnees1)

# Sous-sélection de deux variables
donnees2 <- subset(donnees1, select=c(Commune, Population.totale))

# moyenne d'échantillon
xbar <- mean(donnees2$Population.totale)
xbar <- round(xbar,0)

# IDC de mu
idcmoy <- t.test(donnees2$Population.totale)$conf.int
# Arrondir à 2 décimales (par défaut)
idcmoy <- round(idcmoy, 2)

# Nombre d'habitants total estimé
T_est <- N*xbar
T_est

#IDC de T
idcT = idcmoy*N
idcT
idcTot <- paste("[", round(idcT[1],2), "/", round(idcT[2],2), "]")

#Marge d'erreur
marge = (idcT[2]-idcT[1])/2
marge

# Enregistrement de l'estimation courante
new_row = data.frame(Pop_exacte = T, Pop_estimee = T_est, IDC = idcTot, Marge = marge)
resultats = rbind(resultats, new_row)
}

# Écriture du csv
print(resultats)
write.csv2(resultats, "resultats.csv")

# _____ Échantillonnage aléatoire stratifié _____

# Indicateurs de tendance centrale
summary(donnees$Population.totale)
```

```
# Découpage en 4 strates
```

```
donnees$strate <- cut(donnees$Population.totale,  
  breaks = c(0, 1000, 5000, 20000, 100000000),  
  labels = c(1, 2, 3, 4))
```

```
# Extraction des colonnes utiles
```

```
donneesstrat <- donnees[, c("Commune", "Population.totale", "strate")]
```

```
# Affiche les 6 premières lignes
```

```
head(donneesstrat)
```

```
# Tri par strate croissante
```

```
data <- donneesstrat[order(donneesstrat$strate), ]
```

```
# Affiche les 6 premières lignes
```

```
head(data)
```

```
# Effectif des strates
```

```
Nh <- table(data$strate)
```

```
Nh
```

```
# Taille totale de l'échantillon stratifié
```

```
N <- sum(Nh)
```

```
N
```

```
# Poids des strates
```

```
gh <- Nh / N
```

```
gh
```

```
# Échantillon de taille n = 100
```

```
n <- 100
```

```
# Allocations proportionnelles aux effectifs des strates
```

```
nh <- round(c(n * Nh[1]/N, n * Nh[2]/N, n * Nh[3]/N, n * Nh[4]/N))
```

```
nh = c(51, 28, 15, 6)
```

```
# Taux de sondage dans les strates
```

```
fh <- nh / Nh
```

```
fh
```

```
# Initialisation du data frame résultats
```

```
resultats_strat <- data.frame(Pop_exacte = numeric(),
```

```
  Pop_estimee = numeric(),
```

```
  IDC      = character(),
```

```
  Marge    = numeric())
```

```
# Boucle de 1 à 10
```

```
for (i in 1:10) {
```

```
  # Tirage stratifié sans remise dans chaque strate
```

```
  st <- strata(data, stratanames = c("strate"), size = nh, method = "srswr")
```

```
  data1 <- getdata(data, st)
```

```
  # Affiche les 6 premières lignes
```

```
head(data1)
```

```
# Définition des 4 sous-échantillons
```

```
ech1 <- data1[data1$strate == 1, ]  
ech2 <- data1[data1$strate == 2, ]  
ech3 <- data1[data1$strate == 3, ]  
ech4 <- data1[data1$strate == 4, ]
```

```
# Moyennes des 4 sous-échantillons
```

```
m1 <- mean(ech1$Population.totale)  
m2 <- mean(ech2$Population.totale)  
m3 <- mean(ech3$Population.totale)  
m4 <- mean(ech4$Population.totale)
```

```
# Variances des 4 sous-échantillons
```

```
var1 <- var(ech1$Population.totale)  
var2 <- var(ech2$Population.totale)  
var3 <- var(ech3$Population.totale)  
var4 <- var(ech4$Population.totale)
```

```
# Moyenne stratifiée estimée
```

```
Xbarst <- (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4) / N
```

```
# Estimation de la variance de Xbarst
```

```
varXbarst <- (gh[1]^2) * (1 - fh[1]) * var1/nh[1] +  
  (gh[2]^2) * (1 - fh[2]) * var2/nh[2] +  
  (gh[3]^2) * (1 - fh[3]) * var3/nh[3] +  
  (gh[4]^2) * (1 - fh[4]) * var4/nh[4]
```

```
# IDC de mu à 95%
```

```
idcmoy <- c(Xbarst - 1.96 * sqrt(varXbarst),  
  Xbarst + 1.96 * sqrt(varXbarst))
```

```
# Estimation de T_strat
```

```
T_strat <- N * Xbarst
```

```
# IDC de T
```

```
idcT <- idcmoy * N  
idcTot <- paste("[", round(idcT[1], 2), "/", round(idcT[2], 2), ""])
```

```
# Marge d'erreur
```

```
marge <- (idcT[2] - idcT[1]) / 2
```

```
# Ajout d'une ligne aux résultats
```

```
new_row <- data.frame(Pop_exacte = T,  
  Pop_estimee = round(T_strat, 0),  
  IDC = idcTot,  
  Marge = round(marge, 2))  
resultats_strat <- rbind(resultats_strat, new_row)  
}
```

Écriture du csv

```
print(resultats_strat)
write.csv2(resultats_strat, "resultats_strat.csv")
```

_____ Traitement de données d'enquête _____

Test du khi-deux d'indépendance des tableaux précédents

```
test_niv <- chisq.test(tabniv)
test_sexe <- chisq.test(tabsexe)
test_fumer <- chisq.test(tabfumer)
test_alt <- chisq.test(tabalt)
test_form <- chisq.test(tabform)
```

Valeurs théoriques

```
test_sexe$expected
test_fumer$expected
test_alt$expected
test_form$expected
```

p-valeurs

```
test_niv$p.value
test_sexe$p.value
test_fumer$p.value
test_alt$p.value
test_form$p.value
```

Contributions

```
(test_niv$residuals)^2
(test_sexe$residuals)^2
(test_fumer$residuals)^2
(test_alt$residuals)^2
(test_form$residuals)^2
```

Création du tableau

```
resultats <- data.frame(Variable = c("niveau", "sexe", "fumer", "alternant", "deptformation"),
  Khi2 = c(test_niv$statistic,
    test_sexe$statistic,
    test_fumer$statistic,
    test_alt$statistic,
    test_form$statistic),

  ddl = c(test_niv$parameter,
    test_sexe$parameter,
    test_fumer$parameter,
    test_alt$parameter,
    test_form$parameter),

  p_value = c(test_niv$p.value,
    test_sexe$p.value,
```

```
    test_fumer$p.value,
    test_alt$p.value,
    test_form$p.value)
)

# Relations significatives ou non
resultats$Conclusion <- ifelse(resultats$p_value < 0.05, "Significatif", "Non significatif")

# V de Cramer tabniv
p_tabniv=nrow(tabniv)
q_tabniv=ncol(tabniv)
n_tabniv=sum(tabniv)
m_tabniv=min(p_tabniv-1,q_tabniv-1)
V_tabniv=sqrt(test_niv$statistic/(n_tabniv*m_tabniv))

# V de Cramer tabsexe
p_tabsexe=nrow(tabsexe)
q_tabsexe=ncol(tabsexe)
n_tabsexe=sum(tabsexe)
m_tabsexe=min(p_tabsexe-1,q_tabsexe-1)
V_tabsexe=sqrt(test_sexe$statistic/(n_tabsexe*m_tabsexe))

# V de Cramer tabfumer
p_tabfumer=nrow(tabfumer)
q_tabfumer=ncol(tabfumer)
n_tabfumer=sum(tabfumer)
m_tabfumer=min(p_tabfumer-1,q_tabfumer-1)
V_tabfumer=sqrt(test_fumer$statistic/(n_tabfumer*m_tabfumer))

# V de Cramer tabalt
p_tabalt=nrow(tabalt)
q_tabalt=ncol(tabalt)
n_tabalt=sum(tabalt)
m_tabalt=min(p_tabalt-1,q_tabalt-1)
V_tabalt=sqrt(test_alt$statistic/(n_tabalt*m_tabalt))

# V de Cramer tabform
p_tabform=nrow(tabform)
q_tabform=ncol(tabform)
n_tabform=sum(tabform)
m_tabform=min(p_tabform-1,q_tabform-1)
V_tabform=sqrt(test_form$statistic/(n_tabform*m_tabform))

# Ajout du V de Cramer au tableau
resultats$Cramer_V <- c(V_tabniv, V_tabsexe, V_tabfumer, V_tabalt, V_tabform)

# Affichage du tableau
resultats
```